

세그멘테이션

1 이미지세그멘테이션의 개요

▼ 세그멘테이션의 정의와 필요성

세그멘테이션의 정의와 필요성

1. 세그멘테이션의 정의

- **세그멘테이션**: 이미지를 픽셀 단위로 분석하여, 각 픽셀이 특정 클래스(예: 사람, 배경 등)에 속하는지 또는 특정 객체(예: 자동차 #1, 자동차 #2 등)에 속하는지를 식별하는 작업.
 - **Semantic Segmentation**:
 - 픽셀마다 클래스 레이블을 할당.
 - 같은 클래스에 속한 모든 픽셀을 하나로 처리.
 - 예: "모든 자동차는 같은 클래스로 묶임."
 - **Instance Segmentation**:
 - 픽셀마다 클래스 레이블뿐만 아니라 개별 객체의 구분도 포함.
 - 같은 클래스 내에서도 개체 간의 구분 가능.
 - 예: "자동차 1, 자동차 2를 별도로 구분."
 - 간단한 비유
 - 이미지 분류: "이 방에 고양이가 있다."
 - 객체 탐지: "고양이는 오른쪽 모서리에 있다."
 - 세그멘테이션: "고양이의 윤곽선이 이 픽셀부터 이 픽셀까지다."
-

2. 세그멘테이션의 필요성

- **이미지 분석의 정밀화**:
 - 이미지 분류(Classification)는 전체 이미지에 대해 하나의 레이블만 예측.
 - 객체 탐지(Object Detection)는 바운딩 박스로 객체를 탐지하지만, 물체의 정확한 경계는 모호.

- 세그멘테이션은 픽셀 수준의 정보를 활용하여 더욱 정밀한 분석 제공.
 - **주요 응용 분야:**
 1. **자율주행:**
 - 도로의 차선, 보행자, 신호등 등 다양한 객체를 픽셀 수준에서 이해.
 2. **의료 영상 처리:**
 - CT, MRI, X-Ray 이미지에서 종양, 장기 등의 정확한 윤곽 탐지.
 3. **위성 영상 분석:**
 - 토지 이용 유형, 건물, 도로 등 지리적 객체 식별.
 4. **AR/VR:**
 - 가상 객체와 실제 환경 간의 정밀한 상호작용 지원.
 - **데이터 활용의 효율성:**
 - 픽셀 단위로 정보를 제공함으로써 AI 모델의 이해도를 높이고, 더욱 풍부한 분석 결과 제공.
 - 객체의 경계, 크기, 모양 등 상세한 정보를 제공하여 다양한 실무 문제 해결 가능.
-

3. 세그멘테이션의 어려움

- **픽셀 단위의 복잡도:**
 - 고해상도 이미지에서는 수백만 개의 픽셀을 처리해야 함.
 - **클래스 불균형 문제:**
 - 객체와 배경의 비율이 크게 차이 나는 경우가 많음.
 - 예: 도로에서 차선은 픽셀이 적고 배경은 많음.
 - **라벨링 비용:**
 - 픽셀 단위로 레이블링하는 작업은 비용이 높고 시간 소요가 큼.
 - **모델의 일반화:**
 - 다양한 환경에서 일관된 성능을 유지하는 것이 도전 과제.
-

4. 세그멘테이션의 진화

- **과거:**

- 전통적 방법(예: SIFT, SURF)으로 경계 탐지 및 세그멘테이션 수행.
- 낮은 정확도와 제한된 활용 가능성.
- **현대:**
 - 딥러닝의 등장으로 세그멘테이션 정확도와 속도 대폭 향상.
 - CNN 기반의 Fully Convolutional Networks(FCN), U-Net 등이 선두 주자로 자리 잡음.

▼ Segmentation의 종류

5. 한눈에 보는 차이

- **Semantic Segmentation:** "이 이미지는 차량과 도로로 이루어져 있다."
- **Instance Segmentation:** "여기에는 차량 3대가 각각 다른 위치에 있다."
- **Panoptic Segmentation:** "차량 A, 차량 B, 도로는 각각 어디에 위치해 있는가?"

▼ 주요 응용 분야 및 데이터셋 소개

주요 응용 분야 및 데이터셋 소개

1. 주요 응용 분야

(1) 의료 영상 분석

- **응용 분야:**
 - CT, MRI, 초음파 등 의료 영상에서 특정 장기, 병변(종양 등)을 픽셀 단위로 분리.
- **목표:**
 - 병변의 정확한 위치와 크기를 측정해 진단 보조.
- **대표 사례:**
 - **간 종양 탐지:** 간 CT 이미지를 분석하여 종양의 경계를 세그멘테이션.
 - **심장 구조 분석:** 심장의 심실과 심벽을 분리해 심혈관 질환 연구.

(2) 자율 주행

- 응용 분야:
 - 도로 위 객체(차량, 보행자, 도로, 신호등)와 배경을 분리.
- 목표:
 - 차량과 보행자의 움직임 예측, 충돌 방지.
- 대표 사례:
 - Semantic Segmentation: 도로, 차선, 배경 구분.
 - Instance Segmentation: 차량, 보행자, 자전거를 개별 객체로 구분.

(3) 위성 및 항공 영상 분석

- 응용 분야:
 - 위성 이미지에서 건물, 강, 도로, 농지 등의 픽셀 분리.
- 목표:
 - 도시 계획, 재난 관리, 환경 보호.
- 대표 사례:
 - 건물의 위치와 크기를 세그멘테이션하여 건축밀도를 분석.
 - 홍수로 인한 침수 지역 탐지.

(4) 증강 현실 (AR) 및 가상 현실 (VR)

- 응용 분야:
 - 객체와 배경을 분리하여 가상 객체와 상호작용.
- 목표:
 - 실시간 객체 추적 및 증강 현실 콘텐츠 렌더링.
- 대표 사례:
 - AR 기반 가구 배치 시 배경과 가구 객체를 분리.

(5) 영상 편집 및 생성

- 응용 분야:
 - 이미지나 비디오에서 객체를 분리해 조작.
- 목표:

- 배경 제거, 객체 이동, 재구성.
 - 대표 사례:
 - 배경을 투명화하거나 다른 배경으로 대체.
-

2. 주요 데이터셋 소개

(1) COCO (Common Objects in Context)

- 특징:
 - 80개 클래스, 약 20만 개 이미지, 약 150만 개의 객체 어노테이션.
 - Semantic Segmentation과 Instance Segmentation 모두 지원.
- 적용 사례:
 - 일상적인 객체(사람, 자동차, 동물 등) 인식 및 분리.

(2) PASCAL VOC

- 특징:
 - 20개 클래스, 약 11,000장 이미지.
 - Semantic Segmentation과 객체 탐지를 지원.
- 적용 사례:
 - 도로 위 차량 탐지, 간단한 객체 인식 연구.

(3) Cityscapes

- 특징:
 - 자율 주행을 위한 도시 거리 이미지.
 - 19개 클래스, 약 5,000장 이미지.
- 적용 사례:
 - 도로, 보행자, 차량, 표지판 등 자율 주행 환경 세그멘테이션.

(4) ADE20K

- 특징:
 - 150개 클래스, 약 20,000장 이미지.
 - 복합 환경 세그멘테이션 (실내, 실외 모두 포함).

- 적용 사례:
 - 복잡한 장면 분석, 고밀도 환경 연구.

(5) Medical Segmentation Decathlon

- 특징:
 - 다양한 의료 영상(CT, MRI 등)에서 10가지 태스크 제공.
 - 데이터 크기 및 해상도가 매우 높음.
- 적용 사례:
 - 의료 영상 분석 연구 (간 종양, 심장 MRI 등).

(6) DeepGlobe Land Cover

- 특징:
 - 위성 이미지에서 토지 유형 분류.
 - 농지, 도시, 강, 숲 등의 클래스 제공.
- 적용 사례:
 - 환경 보호, 도시 계획, 재난 관리.

3. 데이터셋 선택 기준

- 태스크에 맞는 데이터셋 선택:
 - **Semantic Segmentation:** COCO, ADE20K, Cityscapes.
 - **Instance Segmentation:** COCO, PASCAL VOC.
 - 특정 도메인:
 - 의료: Medical Segmentation Decathlon.
 - 위성: DeepGlobe Land Cover.
- 데이터셋 크기:
 - 대규모 데이터셋: 모델의 일반화 성능을 높임.
 - 소규모 데이터셋: 간단한 실험 및 프로토타이핑에 적합.

2 Semantic Segmentation

▼ Fully Convolutional Networks (FCN)

Fully Convolutional Networks (FCN)


1. FCN 소개

- FCN이란?
 - 2015년 Long et al.이 제안한 최초의 End-to-End Semantic Segmentation 모델.
 - Fully Connected Layer 대신 Convolutional Layer를 활용하여 임의 크기의 입력 이미지를 처리.
 - 픽셀 단위의 분류를 가능하게 하는 획기적인 모델.
 - 주요 논문
 - Long et al., "Fully Convolutional Networks for Semantic Segmentation," 2015.
-

2. FCN의 필요성 및 배경

- 기존 모델의 한계
 - 기존 CNN은 Fully Connected Layer를 사용하여 고정 크기의 입력 이미지만 처리 가능.
 - 픽셀 단위의 출력이 필요한 세그멘테이션에는 적합하지 않음.
 - FCN의 목표
 - Fully Connected Layer를 Convolutional Layer로 대체하여 임의 크기의 입력 이미지 처리.
 - 모든 픽셀에 대해 클래스 레이블을 할당할 수 있는 End-to-End 학습.
-

3. FCN의 구조 및 작동 원리



• 구조의 핵심 특징

- Convolution 및 Pooling 계층을 사용하여 특징을 추출.
- Fully Connected Layer를 제거하고 대신 Convolution으로 대체.
- Upsampling(Deconvolution)을 통해 원래 크기로 복원.

• 구체적인 구조

1. Encoder 단계:

- CNN 계층(예: VGG16)을 사용하여 입력 이미지를 저해상도의 특징 맵으로 변환.
- Max Pooling으로 공간 정보를 축소하며 특징을 추출.

2. Decoder 단계:

- Transposed Convolution(Upsampling)으로 특징 맵을 원래 크기로 복원.
- 업샘플링된 결과를 최종 출력으로 매핑.

3. Skip Connection:

- 중간 계층의 고해상도 정보를 Decoder 단계로 전달하여 세밀한 복원을 지원.

4. 최종 출력:

- 1×1 Convolution을 사용하여 각 픽셀에 클래스 확률을 할당.

4. FCN의 주요 아이디어

- **4.1. Fully Convolutional Layer**

- Fully Connected Layer를 Convolutional Layer로 대체하여 입력 크기에 상관없이 동작.
- 고해상도 공간 정보를 보존하며 픽셀 단위의 예측 가능.

- **4.2. Upsampling (Deconvolution)**

- Pooling 계층에서 손실된 공간 정보를 복구하기 위해 Transposed Convolution 도입.
- 특징 맵의 해상도를 점진적으로 복원.
- **(추가 설명) 업샘플링이란?**
 - 업샘플링(Up-sampling)은 입력 데이터의 공간 해상도를 늘리는 과정으로, 작은 크기의 이미지를 더 큰 크기로 확장하는 것을 의미합니다.
 - 목표는 이미지의 픽셀 밀도를 높이거나, 낮은 해상도의 특징 맵(feature map)을 원래 크기로 복원하는 데 있습니다.
 - **직관적 이해**
 - 업샘플링은 마치 작은 이미지를 확대하는 것과 비슷합니다.
 - 예: 4x4 크기의 이미지를 8x8로 확대.
 - 일반적인 업샘플링 기법:
 - 1. Nearest Neighbor Interpolation**
 - 각 픽셀 값을 가까운 픽셀 값으로 복사.
 - 간단하지만 픽셀화된 이미지를 생성.
 - 2. Bilinear Interpolation**
 - 주변 픽셀 값을 선형적으로 보간하여 매끄러운 이미지를 생성.
 - 연산량이 증가하지만 결과가 더 부드러움.
 - 3. Transposed Convolution (Deconvolution)**
 - 학습 가능한 가중치를 통해 업샘플링.
 - 단순한 보간법이 아닌, 더 복잡한 공간적 정보를 학습.


- **4.3. Skip Connection**

- 중간 계층의 고해상도 정보를 결합하여 세밀한 경계 복원 가능.

- FCN에서 사용된 Skip Connection은 U-Net 등에서 확장된 형태로 활용됨.

5. FCN의 업샘플링

- Transposed Convolution



Backwards strided convolution
= Upsampling
= Deconvolution

- 축소된 특징 맵을 원래 크기로 복원하는 과정.
- 입력 데이터를 확장하기 위해 특별히 설계된 컨볼루션 연산.
- 과정:
 1. 기본 컨볼루션 연산의 역방향으로 작동.
 2. 입력 데이터를 확대하여 특정 커널(kernel)을 적용.
 3. 학습 가능한 가중치를 통해 출력 값을 조정.
- FCN에서는 Transposed Convolution을 사용해 축소된 특징 맵을 단계적으로 확장.

- Skip Connection

- 업샘플링된 출력에 중간 계층의 고해상도 특징을 추가.
- 고해상도의 세밀한 정보를 보존하여 더 나은 픽셀 단위의 예측 가능.

6. FCN의 Loss 함수와 학습

- Loss 함수 정의
 - 픽셀 단위로 Cross-Entropy를 계산하여 모델 성능을 평가.
 - 각 픽셀의 클래스 확률을 Softmax 함수로 계산 후 크로스 엔트로피 적용.

- Loss 함수 수식

$$E = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log(\hat{y}_{i,c})$$

- N: 이미지의 픽셀 수.
- C: 클래스 수.
- $y_{i,c}$: 픽셀 i가 클래스 c에 속할 확률(실제값).
- $\hat{y}_{i,c}$: 모델이 예측한 픽셀 i의 클래스 c 확률.
- 학습 방식
 - End-to-End 방식으로 학습.
 - Adam 또는 SGD와 같은 최적화 알고리즘 사용.

7. FCN의 장점과 단점

- 장점:
 - 픽셀 단위의 End-to-End 학습 가능.
 - 다양한 네트워크(VGG, ResNet 등)와 결합 용이.
 - Skip Connection으로 경계 복원 능력 향상.
- 단점:
 - 단순한 업샘플링 방식으로 인해 세밀한 경계 복원에 한계.
 - 복잡한 객체가 많은 장면에서 성능 저하.

▼ U-Net

U-Net: Semantic Segmentation의 핵심 모델

1. U-Net 소개

- U-Net이란?

- 2015년 Ronneberger et al.이 제안한 Semantic Segmentation 모델로, 특히 의료 영상 분석에 특화.
- FCN의 발전된 형태로 대칭적인 U자형 구조를 가짐.
- 고해상도 공간 정보를 보존하며 세그멘테이션 성능을 극대화.

- 주요 논문

- Ronneberger et al., "U-Net: Convolutional Networks for Biomedical Image Segmentation," 2015.
-

2. U-Net의 필요성 및 배경


- 기존 FCN의 한계

- 업샘플링 과정에서 정보 손실이 발생, 세부적인 경계 복원이 어려움.
- Encoder 단계에서 추출한 고해상도 정보를 Decoder에서 효과적으로 활용하지 못함.

- U-Net의 목표

- FCN의 단점을 보완하며, 세부적인 경계까지 복원 가능한 세그멘테이션 모델 제안.
 - Skip Connection을 활용하여 고해상도와 저해상도 특징을 결합.
-

3. U-Net의 구조 및 작동 원리



• 대칭적인 Encoder-Decoder 구조

- **Encoder (Contracting Path):** 컨볼루션 및 Max Pooling으로 특징 추출 및 공간 축소.
- **Decoder (Expanding Path):** Transposed Convolution과 Skip Connection으로 원래 크기 복원.
- **Bottleneck:** 가장 좁은 부분에서 추상화된 고수준 특징 학습.
- **Skip Connection:** 동일한 단계의 Encoder와 Decoder를 연결해 고해상도 정보를 복원.

• 구체적인 구조

1. Encoder 단계:

- 두 개의 3×3 Convolution (ReLU 활성화) 및 Max Pooling으로 구성.
- 특징 맵의 크기를 절반으로 줄이면서 채널 수는 두 배로 증가.

2. Bottleneck 단계:

- 네트워크의 가장 깊은 부분으로, 고수준의 특징을 학습.

3. Decoder 단계:

- Transposed Convolution(업샘플링)으로 공간 해상도 복원.

- Encoder에서 넘어온 Skip Connection과 결합 후 두 개의 3×3 Convolution (ReLU 활성화).

4. 최종 출력:

- 1×1 Convolution으로 각 픽셀에 클래스 확률을 할당.
- Softmax 또는 Sigmoid를 사용해 결과 생성.

4. U-Net의 주요 아이디어

• 4.1. Skip Connection

◦ 역할 및 효과:

- Encoder에서 학습한 고해상도 정보를 Decoder로 전달.
- 정보 손실을 방지하고 세밀한 경계를 복원.

◦ FCN과의 차이:

- U-Net은 다중 Skip Connection을 활용하여 다양한 해상도의 정보를 결합.

• 4.2. Effective Upsampling (Transposed Convolution)

◦ Transposed Convolution이란?

- 컨볼루션 연산의 반대 작업으로, 작은 특징 맵을 큰 크기로 복원.

◦ U-Net의 업샘플링 차별점:

- Skip Connection으로 보완된 고해상도 정보를 추가.
- 업샘플링 과정에서 발생하는 정보 손실을 최소화.

5. Loss 함수와 학습

• Loss 함수 정의

- 픽셀 단위로 Cross-Entropy를 계산하며, 각 픽셀의 Loss에 가중치(weight map)를 곱하여 학습.
- 경계선 픽셀에서 더 높은 가중치를 부여.

• Loss 함수 수식

$$E = \sum_{x \in \Omega} w(x) \cdot \log(p(x))$$

- Ω : 이미지의 모든 픽셀 집합.
- $w(x)$: 픽셀 x 의 가중치.
- $p(x)$: 픽셀 x 의 예측 확률.

• Weight Map 계산 방법

- 경계선 픽셀을 강조하기 위해 가우시안 분포 기반의 가중치를 사용.

$$w(x) \propto \exp(-d_1(x)^2 - d_2(x)^2)$$

- $d_1(x)$: 픽셀 x 와 가장 가까운 객체 경계까지의 거리.
- $d_2(x)$: 픽셀 x 와 두 번째로 가까운 객체 경계까지의 거리.
- 클래스 불균형 보정을 위한 기본 가중치 포함.
- 경계선 강조의 효과
 - 경계선 픽셀에서의 예측 정확도를 높여 세밀한 세그멘테이션 결과 생성.

6. U-Net과 FCN의 비교

• 구조 비교

특징	FCN	U-Net
Skip Connection	일부 계층에서만 연결	모든 단계에서 연결
Decoder 구조	단순 업샘플링	업샘플링 + Skip Connection 결합
복원 성능	경계 복원이 제한적	경계 복원이 우수
응용 분야	일반적인 세그멘테이션	세밀한 세그멘테이션 (예: 의료 영상)

• 장단점 비교

- **FCN의 장점:**
 - 간단한 구조로 효율적 학습 가능.
 - 다양한 네트워크와 결합 용이.
- **U-Net의 장점:**
 - 세밀한 복원이 필요한 응용에서 탁월한 성능.
 - Skip Connection을 통해 높은 해상도의 세그멘테이션 가능.

7. U-Net의 장점과 단점

- **장점:**
 - **고해상도 세그멘테이션:** Skip Connection을 통해 세부적인 경계 복원.
 - **데이터 효율성:** 제한된 데이터셋에서도 높은 성능.
 - **다양한 확장 가능성:** 여러 변형 모델로 발전.
- **단점:**
 - 연산량과 메모리 사용량이 많음.
 - 복잡한 장면에서 모든 객체를 정확히 구분하기 어려움.