

Semantic Segmentation

Fully Convolutional Networks (FCN)


1. FCN 소개

- FCN이란?
 - 2015년 Long et al.이 제안한 최초의 End-to-End Semantic Segmentation 모델.
 - Fully Connected Layer 대신 Convolutional Layer를 활용하여 임의 크기의 입력 이미지를 처리.
 - 픽셀 단위의 분류를 가능하게 하는 획기적인 모델.
 - 주요 논문
 - Long et al., "Fully Convolutional Networks for Semantic Segmentation," 2015.
-

2. FCN의 필요성 및 배경

- 기존 모델의 한계
 - 기존 CNN은 Fully Connected Layer를 사용하여 고정 크기의 입력 이미지만 처리 가능.
 - 픽셀 단위의 출력이 필요한 세그멘테이션에는 적합하지 않음.
 - FCN의 목표
 - Fully Connected Layer를 Convolutional Layer로 대체하여 임의 크기의 입력 이미지 처리.
 - 모든 픽셀에 대해 클래스 레이블을 할당할 수 있는 End-to-End 학습.
-

3. FCN의 구조 및 작동 원리



• 구조의 핵심 특징

- Convolution 및 Pooling 계층을 사용하여 특징을 추출.
- Fully Connected Layer를 제거하고 대신 Convolution으로 대체.
- Upsampling(Deconvolution)을 통해 원래 크기로 복원.

• 구체적인 구조

1. Encoder 단계:

- CNN 계층(예: VGG16)을 사용하여 입력 이미지를 저해상도의 특징 맵으로 변환.
- Max Pooling으로 공간 정보를 축소하며 특징을 추출.

2. Decoder 단계:

- Transposed Convolution(Upsampling)으로 특징 맵을 원래 크기로 복원.
- 업샘플링된 결과를 최종 출력으로 매핑.

3. Skip Connection:

- 중간 계층의 고해상도 정보를 Decoder 단계로 전달하여 세밀한 복원을 지원.

4. 최종 출력:

- 1×1 Convolution을 사용하여 각 픽셀에 클래스 확률을 할당.

4. FCN의 주요 아이디어

- **4.1. Fully Convolutional Layer**

- Fully Connected Layer를 Convolutional Layer로 대체하여 입력 크기에 상관 없이 동작.
- 고해상도 공간 정보를 보존하며 픽셀 단위의 예측 가능.

- **4.2. Upsampling (Deconvolution)**

- Pooling 계층에서 손실된 공간 정보를 복구하기 위해 Transposed Convolution 도입.
- 특징 맵의 해상도를 점진적으로 복원.

- **(추가 설명) 업샘플링이란?**

- 업샘플링(Up-sampling)은 입력 데이터의 공간 해상도를 늘리는 과정으로, 작은 크기의 이미지를 더 큰 크기로 확장하는 것을 의미합니다.
- 목표는 이미지의 픽셀 밀도를 높이거나, 낮은 해상도의 특징 맵(feature map)을 원래 크기로 복원하는 데 있습니다.

- **직관적 이해**

- 업샘플링은 마치 작은 이미지를 확대하는 것과 비슷합니다.
 - 예: 4x4 크기의 이미지를 8x8로 확대.
- 일반적인 업샘플링 기법:

- 1. **Nearest Neighbor Interpolation**

- 각 픽셀 값을 가까운 픽셀 값으로 복사.
 - 간단하지만 픽셀화된 이미지를 생성.

- 2. **Bilinear Interpolation**

- 주변 픽셀 값을 선형적으로 보간하여 매끄러운 이미지를 생성.
 - 연산량이 증가하지만 결과가 더 부드러움.

- 3. **Transposed Convolution (Deconvolution)**


- 학습 가능한 가중치를 통해 업샘플링.
 - 단순한 보간법이 아닌, 더 복잡한 공간적 정보를 학습.

- **4.3. Skip Connection**

- 중간 계층의 고해상도 정보를 결합하여 세밀한 경계 복원 가능.
- FCN에서 사용된 Skip Connection은 U-Net 등에서 확장된 형태로 활용됨.

5. FCN의 업샘플링

- Transposed Convolution



Backwards strided convolution
= Upsampling
= Deconvolution

- 축소된 특징 맵을 원래 크기로 복원하는 과정.
- 입력 데이터를 확장하기 위해 특별히 설계된 컨볼루션 연산.
- 과정:
 1. 기본 컨볼루션 연산의 역방향으로 작동.
 2. 입력 데이터를 확대하여 특정 커널(kernel)을 적용.
 3. 학습 가능한 가중치를 통해 출력 값을 조정.
- FCN에서는 Transposed Convolution을 사용해 축소된 특징 맵을 단계적으로 확장.

- Skip Connection

- 업샘플링된 출력에 중간 계층의 고해상도 특징을 추가.
- 고해상도의 세밀한 정보를 보존하여 더 나은 픽셀 단위의 예측 가능.

6. FCN의 Loss 함수와 학습

- **Loss 함수 정의**

- 픽셀 단위로 Cross-Entropy를 계산하여 모델 성능을 평가.
- 각 픽셀의 클래스 확률을 Softmax 함수로 계산 후 크로스 엔트로피 적용.

- **Loss 함수 수식**

$$E = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log(\hat{y}_{i,c})$$

- N: 이미지의 픽셀 수.
- C: 클래스 수.
- $y_{i,c}$: 픽셀 i가 클래스 c에 속할 확률(실제값).
- $\hat{y}_{i,c}$: 모델이 예측한 픽셀 i의 클래스 c 확률.

- **학습 방식**

- End-to-End 방식으로 학습.
 - Adam 또는 SGD와 같은 최적화 알고리즘 사용.
-

7. FCN의 장점과 단점

- **장점:**

- 픽셀 단위의 End-to-End 학습 가능.
- 다양한 네트워크(VGG, ResNet 등)와 결합 용이.
- Skip Connection으로 경계 복원 능력 향상.

- **단점:**

- 단순한 업샘플링 방식으로 인해 세밀한 경계 복원에 한계.
- 복잡한 객체가 많은 장면에서 성능 저하.

Instance Segmentation

이미지 생성 개요

