

U-net

U-Net: Semantic Segmentation의 핵심 모델


1. U-Net 소개

- U-Net이란?
 - 2015년 Ronneberger et al.이 제안한 Semantic Segmentation 모델로, 특히 의료 영상 분석에 특화.
 - FCN의 발전된 형태로 대칭적인 U자형 구조를 가짐.
 - 고해상도 공간 정보를 보존하며 세그멘테이션 성능을 극대화.
 - 주요 논문
 - Ronneberger et al., "U-Net: Convolutional Networks for Biomedical Image Segmentation," 2015.
-

2. U-Net의 필요성 및 배경

- 기존 FCN의 한계
 - 업샘플링 과정에서 정보 손실이 발생, 세부적인 경계 복원이 어려움.
 - Encoder 단계에서 추출한 고해상도 정보를 Decoder에서 효과적으로 활용하지 못함.
 - U-Net의 목표
 - FCN의 단점을 보완하며, 세부적인 경계까지 복원 가능한 세그멘테이션 모델 제안.
 - Skip Connection을 활용하여 고해상도와 저해상도 특징을 결합.
-

3. U-Net의 구조 및 작동 원리



• 대칭적인 Encoder-Decoder 구조

- **Encoder (Contracting Path):** 컨볼루션 및 Max Pooling으로 특징 추출 및 공간 축소.
- **Decoder (Expanding Path):** Transposed Convolution과 Skip Connection으로 원래 크기 복원.
- **Bottleneck:** 가장 좁은 부분에서 추상화된 고수준 특징 학습.
- **Skip Connection:** 동일한 단계의 Encoder와 Decoder를 연결해 고해상도 정보를 복원.

• 구체적인 구조

1. Encoder 단계:

- 두 개의 3×3 Convolution (ReLU 활성화) 및 Max Pooling으로 구성.
- 특징 맵의 크기를 절반으로 줄이면서 채널 수는 두 배로 증가.

2. Bottleneck 단계:

- 네트워크의 가장 깊은 부분으로, 고수준의 특징을 학습.

3. Decoder 단계:

- Transposed Convolution(업샘플링)으로 공간 해상도 복원.

- Encoder에서 넘어온 Skip Connection과 결합 후 두 개의 3×3 Convolution (ReLU 활성화).

4. 최종 출력:

- 1×1 Convolution으로 각 픽셀에 클래스 확률을 할당.
- Softmax 또는 Sigmoid를 사용해 결과 생성.

4. U-Net의 주요 아이디어

• 4.1. Skip Connection

◦ 역할 및 효과:

- Encoder에서 학습한 고해상도 정보를 Decoder로 전달.
- 정보 손실을 방지하고 세밀한 경계를 복원.

◦ FCN과의 차이:

- U-Net은 다중 Skip Connection을 활용하여 다양한 해상도의 정보를 결합.

• 4.2. Effective Upsampling (Transposed Convolution)

◦ Transposed Convolution이란?

- 컨볼루션 연산의 반대 작업으로, 작은 특징 맵을 큰 크기로 복원.

◦ U-Net의 업샘플링 차별점:

- Skip Connection으로 보완된 고해상도 정보를 추가.
- 업샘플링 과정에서 발생하는 정보 손실을 최소화.

5. Loss 함수와 학습

• Loss 함수 정의

- 픽셀 단위로 Cross-Entropy를 계산하며, 각 픽셀의 Loss에 가중치(weight map)를 곱하여 학습.
- 경계선 픽셀에서 더 높은 가중치를 부여.

• Loss 함수 수식

$$E = \sum_{x \in \Omega} w(x) \cdot \log(p(x))$$

- Ω : 이미지의 모든 픽셀 집합.

- $w(x)$: 픽셀 x 의 가중치.
- $p(x)$: 픽셀 x 의 예측 확률.

- **Weight Map 계산 방법**

- 경계선 픽셀을 강조하기 위해 가우시안 분포 기반의 가중치를 사용.

$$w(x) \propto \exp(-d_1(x)^2 - d_2(x)^2)$$

- $d_1(x)$: 픽셀 x 와 가장 가까운 객체 경계까지의 거리.
- $d_2(x)$: 픽셀 x 와 두 번째로 가까운 객체 경계까지의 거리.
- 클래스 불균형 보정을 위한 기본 가중치 포함.
- **경계선 강조의 효과**
 - 경계선 픽셀에서의 예측 정확도를 높여 세밀한 세그멘테이션 결과 생성.

6. U-Net과 FCN의 비교

- **구조 비교**

특징	FCN	U-Net
Skip Connection	일부 계층에서만 연결	모든 단계에서 연결
Decoder 구조	단순 업샘플링	업샘플링 + Skip Connection 결합
복원 성능	경계 복원이 제한적	경계 복원이 우수
응용 분야	일반적인 세그멘테이션	세밀한 세그멘테이션 (예: 의료 영상)

- **장단점 비교**

- **FCN의 장점:**
 - 간단한 구조로 효율적 학습 가능.
 - 다양한 네트워크와 결합 용이.
- **U-Net의 장점:**
 - 세밀한 복원이 필요한 응용에서 탁월한 성능.
 - Skip Connection을 통해 높은 해상도의 세그멘테이션 가능.

7. U-Net의 장점과 단점

- **장점:**

- **고해상도 세그멘테이션:** Skip Connection을 통해 세부적인 경계 복원.
- **데이터 효율성:** 제한된 데이터셋에서도 높은 성능.
- **다양한 확장 가능성:** 여러 변형 모델로 발전.
- **단점:**
 - 연산량과 메모리 사용량이 많음.
 - 복잡한 장면에서 모든 객체를 정확히 구분하기 어려움.