

Instance Segmentation

3 Instance Segmentation

Mask R-CNN


1. Mask R-CNN 소개

- **Mask R-CNN이란?**
 - 2017년 Facebook AI Research(FAIR) 팀이 제안한 Instance Segmentation 모델.
 - Faster R-CNN에 기반하여 객체 감지(Object Detection)와 객체 마스크 생성(Segmentation)을 동시에 수행.
 - 픽셀 단위의 객체 분할을 가능하게 하며, 다양한 응용 분야에서 사용됨.
- **주요 논문**
 - He et al., "Mask R-CNN," 2017.
- **주요 특징**
 - 객체의 위치(바운딩 박스), 클래스, 그리고 픽셀 단위의 마스크를 예측.
 - 다목적 활용이 가능한 높은 유연성과 성능 제공.

2. Mask R-CNN의 필요성 및 배경

- **기존 모델의 한계**
 - Faster R-CNN은 바운딩 박스와 클래스만 예측.
 - 픽셀 단위 분할 정보가 필요한 응용에는 적합하지 않음.
- **Mask R-CNN의 목표**
 - Faster R-CNN 구조를 확장하여 객체의 픽셀 단위 마스크를 학습.
 - Object Detection과 Instance Segmentation을 End-to-End로 통합.

3. Mask R-CNN의 구조 및 작동 원리



3.1. 주요 구성 요소

1. Backbone Network

- Feature Pyramid Network(FPN)와 ResNet을 사용하여 멀티스케일 특징 맵 생성.
- 공간적 해상도와 표현력을 모두 고려한 특징 추출.

2. Region Proposal Network (RPN)

- Faster R-CNN의 RPN과 동일.
- 관심 영역(Region of Interest, RoI)을 예측하여 후보 바운딩 박스 생성.

3. RoI Align

- RoI Pooling의 업그레이드 버전.
- 서브픽셀 수준에서 정확한 위치 정보를 보존.
- 픽셀 정렬 문제를 해결하여 Segmentation 성능 향상.

4. Classification and Bounding Box Regression


- Faster R-CNN과 동일하게 바운딩 박스와 클래스 예측.

5. Segmentation Branch

- 픽셀 단위 마스크 예측.
- 각 RoI에 대해 독립적인 마스크 생성.

4. Mask R-CNN의 주요 아이디어

4.1. RoI Align



1. 기존 RoI Pooling의 문제

• RoI Pooling이란?

- Region Proposal Network(RPN)에서 생성한 후보 영역(Region of Interest, RoI)을 고정된 크기의 특징 맵으로 변환하는 작업.
- Faster R-CNN과 같은 모델에서는 이 과정이 필수적이며, 다양한 크기의 RoI를 통일된 크기로 만들어 Fully Connected Layer에 입력.
- 예를 들어, 다양한 크기의 RoI를 **7x7**로 변환.

• 양자화 오류란?

- RoI Pooling은 RoI의 좌표를 가장 가까운 정수로 반올림(quantization)하여 고정 크기로 변환.
- 이 과정에서 픽셀 위치가 정확히 매칭되지 않아 특징 맵의 정보가 왜곡되거나 손실됨.
- 특히, 물체의 경계나 작은 객체를 다룰 때 손실이 더욱 두드러짐.
- 예:
 - 원래 좌표: (12.4, 8.6) → 양자화: (12, 9).
 - 이로 인해 중요한 경계 정보가 잘못된 위치로 매핑되거나 사라짐.

2. RoI Align의 해결책

• 양자화 제거

- RoI Align은 좌표를 반올림하지 않고, 정확한 부동소수점(float) 좌표를 유지.
- 이를 통해 픽셀 정렬 문제를 해결.

- 예:
 - 원래 좌표: (12.4, 8.6) → 그대로 유지.

- **선형 보간법 사용**

- RoI Align은 특징 맵에서 정확한 좌표에 해당하는 값을 가져오기 위해 **Bilinear Interpolation**을 사용.
- 좌표가 정수 위치에 있지 않은 경우, 주변 픽셀 값을 선형적으로 보간하여 정확한 값을 계산.
- 예:
 - 좌표 (12.4, 8.6)의 값을 계산할 때, 인접한 네 픽셀의 값을 가중 평균하여 보간.
 - 이로 인해 서브픽셀 수준의 정밀도와 공간적 정보 보존 가능.

3. 직관적 이해

a. RoI Pooling과의 차이점

- RoI Pooling은 "픽셀을 대충 맞춰 자른다"는 느낌.
 - 예: 원래의 섬세한 모양을 가진 물체를 "격자 모양"으로 대략 자르는 것과 같음.
- RoI Align은 "픽셀 위치를 정확히 계산해 자른다"는 느낌.
 - 예: 물체의 섬세한 곡선과 모양을 그대로 유지하며 자름.

b. 비유

- RoI Pooling은 마치 저해상도 이미지에서 물체를 자르는 것과 비슷.
- RoI Align은 고해상도 이미지에서 물체를 자르면서, 잘리지 않는 부분까지 선명하게 보존.

4. RoI Align이 가져온 이점

- **정확한 픽셀 매핑**
 - 양자화 과정에서 발생하는 불필요한 오류를 제거하여, 경계나 작은 객체의 세그멘테이션이 더 정확해짐.
- **Segmentation 성능 향상**
 - 세밀한 객체 경계를 처리할 때 더 높은 성능을 보임.
- **활용**

- Mask R-CNN을 포함한 많은 최신 모델에서 필수적인 구성 요소로 자리 잡음.

4.2. 분리된 Segmentation Branch

- Faster R-CNN에 독립적인 Segmentation Branch 추가.
- 각 RoI에 대해 별도의 마스크를 생성.
- 마스크는 고정된 크기(예: 28×28)로 예측되며, 필요시 원래 크기로 Upsampling.

5. Mask R-CNN의 Loss 함수

Mask R-CNN의 손실 함수는 크게 세 부분으로 나뉩니다:

1. Bounding Box Regression Loss
2. Classification Loss
3. Mask Loss

각 손실을 더한 최종 손실 LL은 다음과 같이 표현됩니다:

$$L = L_{\text{cls}} + L_{\text{box}} + L_{\text{mask}}$$

1. Classification Loss (L_{cls})

- 역할: 각 RoI가 특정 클래스에 속할 확률을 예측.
- 손실 함수: Cross-Entropy Loss를 사용.
- 수식:

$$L_{\text{cls}} = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log(\hat{y}_{i,c})$$

- N: RoI의 수.
- C: 클래스의 수.
- $y_{i,c}$: RoI i의 실제 클래스 c.
- $\hat{y}_{i,c}$: 모델이 예측한 클래스 확률.

2. Bounding Box Regression Loss (L_{box})

- 역할: RoI의 예측된 Bounding Box와 실제 Bounding Box 사이의 차이를 최소화.

- **손실 함수:** Smooth L1 Loss를 사용.
 - Smooth L1 Loss는 큰 오차에 대해 L1 Loss처럼 작동하고, 작은 오차에 대해서는 L2 Loss처럼 작동하여 안정적인 학습을 가능하게 함.
- **수식:**

$$L_{\text{box}} = \frac{1}{N} \sum_{i=1}^N \sum_{j \in \{x, y, w, h\}} \text{SmoothL1}(\hat{b}_{i,j} - b_{i,j})$$

- N: RoI의 수.
- $\hat{b}_{i,j}$: 예측된 Bounding Box의 좌표(x, y, w, h).
- $b_{i,j}$: 실제 Bounding Box의 좌표.
- **Smooth L1 Loss 정의:**

$$\text{SmoothL1}(x) = \begin{cases} 0.5x^2 & \text{if } |x| < 1, \\ |x| - 0.5 & \text{otherwise.} \end{cases}$$

3. Mask Loss (L_{mask})

- **역할:** 각 RoI에서 픽셀 단위로 객체의 Segmentation Mask를 예측.
- **손실 함수:** Binary Cross-Entropy Loss를 사용.
 - Mask는 픽셀 단위의 이진 분류 문제로 간주되므로, 각 픽셀에 대해 Binary Cross-Entropy를 계산.
- **수식:**

$$L_{\text{mask}} = -\frac{1}{N} \sum_{i=1}^N \sum_{p=1}^P [m_{i,p} \log(\hat{m}_{i,p}) + (1 - m_{i,p}) \log(1 - \hat{m}_{i,p})]$$

- N: RoI의 수.
- P: Mask의 픽셀 수.
- $m_{i,p}$: RoI i의 픽셀 p에 대한 실제 Mask 값 (0 또는 1).
- $\hat{m}_{i,p}$: 모델이 예측한 픽셀 p의 Mask 값 (확률).

Mask R-CNN Loss의 통합

$$L = L_{\text{cls}} + L_{\text{box}} + L_{\text{mask}}$$

- **최적화 과정:**
 - 모든 손실은 각각의 역할을 고려하여 독립적으로 계산되고 합산.
 - End-to-End 학습을 통해 분류(Classification), 박스 회귀(Bounding Box Regression), 그리고 세그멘테이션(Mask Prediction)을 동시에 학습.
- **핵심 장점:**
 - 세 가지 손실을 조합함으로써 Detection과 Segmentation을 통합적으로 처리 가능.
 - 다양한 객체 크기와 복잡한 경계에서도 높은 성능을 보임.

6. Mask R-CNN의 장점과 단점

- **장점**
 - 정확한 픽셀 단위 분할과 객체 검출을 동시에 수행.
 - RoI Align을 통해 높은 공간적 정밀도 제공.
 - 다양한 객체 크기에 대해 강건한 성능.
- **단점**
 - 높은 연산 비용 및 메모리 사용량.
 - 실시간 처리에는 부적합.
 - 작은 객체나 복잡한 배경에서는 여전히 한계 존재.

7. Mask R-CNN: 모델 평가 및 개선

1. 모델 평가: 평가지표

Mask R-CNN의 성능 평가는 객체 검출(Object Detection)과 세그멘테이션(Segmentation) 작업 각각에 대해 이루어집니다.

1.1. 객체 검출 평가지표

- **Mean Average Precision (mAP)**

- **정의:** 검출된 모든 객체에 대해 정확성과 재현율(Precision-Recall)을 계산하고, 각 클래스별 평균 정밀도를 구한 후 이를 평균화한 값.
- **특징:**
 - Intersection over Union (IoU) 임계값에 따라 성능 평가.
 - 다양한 IoU 기준(예: 0.5, 0.75, 0.5:0.95)에서 성능 측정 가능.
- **수식:**

$$mAP = \frac{1}{C} \sum_{c=1}^C AP_c$$

- C: 클래스의 총 개수.
- AP_c : 클래스 c의 Average Precision.

1.2. 세그멘테이션 평가지표

• Mean Intersection over Union (mIoU)

- **정의:** 예측한 세그멘테이션 영역과 실제 세그멘테이션 영역의 교집합 (Intersection)과 합집합(Union)의 비율을 계산한 뒤, 클래스별 평균을 구함.
- **수식:**

$$mIoU = \frac{1}{C} \sum_{c=1}^C \frac{|P_c \cap T_c|}{|P_c \cup T_c|}$$

- P_c : 클래스 c의 예측 영역.
- T_c : 클래스 c의 실제 영역.
- **특징:**
 - 객체의 위치와 크기뿐만 아니라 픽셀 단위로 정확도를 평가.
 - 세밀한 경계 구분 능력을 평가하는 데 적합.

1.3. 기타 평가 요소

• Runtime 성능:

- 모델의 처리 속도(FPS, Frames Per Second) 측정.
- 실시간 응용에서 중요한 요소.

- **메모리 사용량:**
 - 모델 추론 시 메모리 효율성을 평가.
-

2. 평가 지표 선택 이유

- **mAP:** 객체 검출 성능을 평가하는 데 적합한 기준.
 - IoU를 통해 정확히 객체를 검출했는지 확인 가능.
- **mIoU:** 세그멘테이션 작업에서 픽셀 단위의 정확도를 평가.
 - 픽셀 수준의 세밀한 결과가 필요한 응용에 적합.
- **Runtime 성능:** 실제 시스템에서의 실용성을 판단.
 - 빠른 처리 속도와 효율적인 연산이 중요한 경우 고려.