

GAN


1 GAN의 구조와 작동 원리

GAN의 구조와 작동 원리

1. GAN(Generative Adversarial Network)이란?

- 정의:
 - GAN은 생성자(Generator)와 판별자(Discriminator)의 두 신경망이 경쟁적으로 학습하며 데이터를 생성하는 모델입니다.
 - 생성자는 새로운 데이터를 생성하고, 판별자는 해당 데이터가 실제 데이터인지 가짜 데이터인지 판별합니다.
- 핵심 아이디어:
 - 두 모델 간의 대립(Adversarial) 구조를 통해, 생성자가 점차적으로 진짜같은 데이터를 생성하도록 학습.

2. GAN의 구조



- **Generator (생성자):**
 - 잠재 공간(Latent Space)에서 샘플링한 벡터를 입력으로 받아, 실제 데이터와 비슷한 새로운 데이터를 생성.
 - Fully Connected Layer, Transposed Convolution 등을 사용해 데이터를 생성.
 - 목표: 판별자를 속일 수 있는 "진짜같은" 데이터를 생성.
- **Discriminator (판별자):**

- 입력 데이터가 실제 데이터인지 생성된 데이터인지 판별.
- 일반적으로 Convolutional Neural Network(CNN) 구조를 사용.
- **목표:** 생성자의 출력을 가짜로 판별하고, 실제 데이터는 진짜로 판별.

3. GAN의 학습 과정

1. Generator 학습:

- 생성자는 판별자를 속일 수 있는 데이터를 생성하려고 학습.
- 판별자가 생성 데이터를 진짜 데이터로 잘못 판별하도록 Loss를 최소화.

2. Discriminator 학습:

- 판별자는 생성된 데이터와 실제 데이터를 정확히 구분하는 법을 학습.
- 진짜 데이터를 진짜로, 가짜 데이터를 가짜로 판별하도록 Loss를 최소화.

3. Adversarial Learning:

- 생성자와 판별자가 서로 경쟁하며 학습.
- 생성자는 판별자를 속이기 위해 더 진짜 같은 데이터를 생성, 판별자는 이를 구분하기 위해 더 강력한 특성을 학습.

4. GAN의 손실 함수

GAN의 손실 함수는 생성자와 판별자가 서로 상반된 목표를 가지고 학습하기 위해 정의됩니다.

• 수학적 정의:

- 판별자:

$$\mathcal{L}_D = -\mathbb{E}_{x \sim p_{\text{data}}(x)}[\log D(x)] - \mathbb{E}_{z \sim p_z(z)}[\log(1 - D(G(z)))]$$

- $D(x)$: 판별자가 실제 데이터를 진짜로 판별할 확률.
- $1 - D(G(z))$: 판별자가 생성된 데이터를 가짜로 판별할 확률
- 진짜 데이터를 잘 구분할수록, 가짜 데이터를 잘 구분할수록 손실이 작아짐

- 생성자:

$$\mathcal{L}_G = -\mathbb{E}_{z \sim p_z(z)}[\log D(G(z))]$$

- $D(G(z))$: 판별자가 생성 데이터를 진짜로 판별할 확률.
- 생성자는 판별자를 속이기 위해 $D(G(z))$ 를 최대화 → 손실 최소화

- 직관적 이해:
 - 판별자는 진짜와 가짜를 올바르게 구분하려고 노력.
 - 생성자는 판별자를 속이기 위해 더욱 진짜 같은 데이터를 생성.

5. GAN의 학습 알고리즘

1. 단계적 학습:

- 판별자를 고정한 상태에서 생성자를 학습.
- 생성자를 고정한 상태에서 판별자를 학습.
- 이러한 과정을 번갈아가며 반복.

2. 최적화 과정:

- 생성자는 손실을 최소화하도록, 판별자는 손실을 최대화하도록 학습.
- Adversarial Loss는 Minmax 게임의 형태로 표현:

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{\text{data}}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$

6. GAN의 직관적 이해

- 경쟁적 학습:
 - 생성자는 "가짜 데이터를 만들어내는 위조범".
 - 판별자는 "위조범을 찾아내는 경찰".
 - 위조범과 경찰이 서로 경쟁하면서, 위조범은 점점 더 정교한 위조품을 만들어냄.
- 잠재 공간(Latent Space):
 - 잠재 공간은 생성자가 학습하는 "창의적인 공간".
 - 이 공간에서 샘플링된 노이즈 벡터는 생성자의 입력으로 사용.

2 GAN 학습의 어려움 및 해결 방안

GAN 학습의 어려움 및 해결 방안

1. GAN 학습의 주요 어려움

1. 모든 데이터를 커버하지 못하는 현상 (Mode Collapse):

- **현상:**
 - 생성자가 소수의 데이터 모드(특정 패턴)에 집중해 다양한 데이터를 생성하지 못하는 문제.
 - 예: 얼굴 생성에서 특정 표정만 생성되는 현상.
- **원인:**
 - 생성자가 판별자를 속이는 데 지나치게 집중하며 다양한 데이터 분포를 학습하지 못함.

2. 불안정한 학습 (Training Instability):

- **현상:**
 - 생성자와 판별자가 서로 균형 있게 학습하지 못할 경우, 학습이 제대로 진행되지 않음.
 - 판별자가 너무 강하면 생성자가 학습하지 못하고, 반대로 생성자가 너무 강하면 판별자가 무의미해짐.
- **원인:**
 - Loss 함수가 잘 수렴하지 않거나, 생성자와 판별자의 학습 속도 차이로 인해 발생.

3. Gradient Vanishing (기울기 소실):

- **현상:**
 - 판별자의 출력이 극단적인 값(0 또는 1)에 치우치면, 생성자의 기울기 정보가 사라지는 문제.
- **원인:**
 - Sigmoid 활성화 함수와 Binary Cross-Entropy Loss가 결합되어, 극단적 출력에서 기울기가 사라지는 경향.

4. Hyperparameter Tuning의 어려움:

- **현상:**
 - GAN 학습에서 적절한 학습률, Batch Size, 모델 구조 등을 찾기 어렵다.
- **원인:**
 - 생성자와 판별자의 복잡한 상호작용.

2. GAN 학습 문제의 해결 방안

1. Mode Collapse 해결:

- **Solution 1: Minibatch Discrimination**

- 동일한 Batch 내에서 생성된 샘플의 차이를 판별자가 고려하도록 설계.
- 이를 통해 생성자가 더욱 다양한 샘플을 생성하도록 유도.

- **Solution 2: Unrolled GAN**

- 판별자가 생성자보다 너무 빨리 학습하면, 생성자는 판별자의 경사를 제대로 따라가지 못해 학습이 불안정해질 수 있음
- 판별자가 여러 번 업데이트된 결과를 고려하여 생성자를 학습하는 방식
- 생성자가 더 안정적으로 학습할 수 있도록 유도.

2. 불안정한 학습 해결:

- **Solution 1: Wasserstein GAN (WGAN)**

- 기존 GAN의 Binary Cross-Entropy 대신 Wasserstein Distance를 사용해 Loss를 정의.
- Wasserstein Distance는 두 분포 간의 차이를 측정하며, 안정적 학습을 지원.

- **Solution 2: Gradient Penalty**

- WGAN-GP(WGAN with Gradient Penalty)에서는 판별자 기울기의 크기를 제어(1에 가깝게 유지)하여 학습 안정성을 강화.

3. Gradient Vanishing 해결:

- **Solution 1: Label Smoothing**

- 진짜 데이터의 라벨을 1이 아닌 0.9로 조정하여 기울기 정보 손실을 완화.

- **Solution 2: Wasserstein Distance**

- Sigmoid 함수 대신 Linear Activation을 사용하여 기울기 소실 문제를 완화.

4. Hyperparameter Tuning의 개선:

- **Solution 1: Adaptive Learning Rate**

- 생성자와 판별자의 학습률을 동적으로 조정.
- 예: RMSProp 또는 Adam Optimizer의 학습률 조정.

- **Solution 2: Pretraining**

- 판별자 또는 생성자를 사전 학습하여 초기 학습 안정성을 확보.

3. GAN 학습 개선을 위한 추가 기법

1. Progressive Growing

- GAN을 점진적으로 학습하여 고해상도 데이터를 생성.

- 초기에는 낮은 해상도로 시작해 점차 해상도를 높이는 방식.

2. Feature Matching

- 판별자가 단순히 진짜/가짜를 판별하는 대신, 진짜 데이터와 생성 데이터의 특징을 비교하여 학습.

3. Spectral Normalization

- 판별자의 가중치를 정규화하여 학습 안정성을 높이고, 과적합 문제를 완화.
-

3 주요 변형 GAN

주요 변형 GAN

1. 주요 변형 GAN의 필요성

- 기본 GAN의 한계
 - Mode Collapse 문제.
 - 학습 불안정성.
 - 고해상도 및 복잡한 데이터 생성의 어려움.
 - 변형 GAN의 목표
 - 특정 문제를 해결하거나, 새로운 데이터 생성 요구에 부합하도록 GAN을 확장.
-

2. 주요 변형 GAN 소개

2.1. Deep Convolutional GAN (DCGAN)

- 개요:
 - GAN에서 Convolutional Layer를 활용하여 고품질 이미지를 생성.
 - Radford et al., 2015년에 제안.
- 특징:
 - Fully Connected Layer 제거, Convolutional Layer 도입.
 - Batch Normalization과 Leaky ReLU를 사용해 안정적인 학습 지원.
 - 고해상도 이미지 생성에 적합.

- **장점:**
 - Convolutional Layer 덕분에 생성 이미지 품질 향상.
 - 학습 안정성 개선.

2.2. Wasserstein GAN (WGAN)

- **개요:**
 - Loss 함수를 Wasserstein Distance로 변경하여 학습 안정성 확보.
 - Arjovsky et al., 2017년에 제안.
- **특징:**
 - Binary Cross-Entropy 대신 Wasserstein Loss 사용.
 - Lipschitz Continuity를 보장하기 위해 Weight Clipping 사용.
 - Gradient Penalty를 추가한 WGAN-GP로 발전.
- **장점:**
 - 판별자와 생성자 간 균형 유지.
 - Gradient Vanishing 문제 완화.

2.3. Least Squares GAN (LSGAN)

- **개요:**
 - Binary Cross-Entropy 대신 Least Squares Loss를 사용하여 안정성 강화.
 - Mao et al., 2017년에 제안.
- **특징:**
 - BCE Loss는 진짜와 가짜 샘플의 출력 값을 1과 0에 가까이 하도록 학습.
 - Loss 함수가 기울기 소실 문제를 완화.
 - Binary Cross-Entropy Loss에서는 출력값이 **0 또는 1에 가까울수록** 경사가 매우 작아지는 문제가 발생.
 - 반면, Least Squares Loss는 출력값이 **0.5 근처일 때** 경사가 크고, 출력값이 **0 또는 1에 가까울수록** 경사가 작아져 학습이 안정적으로 이루어짐
 - 판별자의 출력값이 0과 1 사이에서 부드럽게 변화하여, 극단적인 학습 대신 더 부드러운 경계(smooth boundary)를 형성
- **장점:**
 - GAN 학습의 안정성을 높이고, 생성 이미지 품질 개선.

2.4. Progressive Growing GAN (PGGAN)

- 개요:
 - 고해상도 이미지 생성을 위해 점진적으로 네트워크를 확장.
 - Karras et al., 2017년에 제안.
- 특징:
 - 학습 초기에는 낮은 해상도로 시작, 점진적으로 고해상도 추가.
 - 안정적인 고해상도 학습 가능.
- 장점:
 - 고해상도 이미지에서 뛰어난 품질 달성.
 - 복잡한 이미지 세부 사항 생성 가능.

2.5. Conditional GAN (cGAN)

- 개요:
 - 생성 과정에 **조건**을 추가하여 특정 분포의 데이터를 생성.
 - Mirza and Osindero, 2014년에 제안.
- 특징:
 - 라벨 정보나 추가 조건을 생성자와 판별자의 입력으로 사용.
 - 특정 클래스, 스타일, 속성을 가진 데이터 생성 가능.
- 장점:
 - 사용자가 원하는 특성을 반영한 이미지 생성.
 - 특정 데이터 생성에 효과적.

2.6. StyleGAN

- 개요:
 - 이미지 스타일 조정을 위한 새로운 아키텍처.
 - Karras et al., 2018년에 제안.
- 특징:
 - Adaptive Instance Normalization (AdaIN)을 활용한 스타일 조정.
 - **Instance Normalization (IN):**
각 이미지의 채널별 평균값과 분산값을 표준화(정규화)하는 과정입니다.

이를 통해 이미지의 **콘텐츠**와 **스타일**을 분리할 수 있습니다.

▪ **Adaptive Instance Normalization (AdaIN):**

Instance Normalization의 결과에 **스타일 정보를 반영한 가중치**를 추가합니다.

즉, 스타일 정보를 활용해 정규화된 특징맵을 조정하는 방식입니다.

- 잠재 공간을 스타일 공간으로 변환하여 이미지 다양성 확보.

• **장점:**

- 고품질 이미지 생성.
- 이미지 속성 조정 가능.

3. 변형 GAN의 비교

모델	주요 특징	장점	한계
DCGAN	Convolutional Layer 기반, Batch Norm 사용	학습 안정성 향상, 고품질 이미지 생성	고해상도 데이터 생성에 한계
WGAN	Wasserstein Distance 사용	학습 안정성 강화, Mode Collapse 완화	Weight Clipping으로 인해 판별자의 표현력이 제한되고 학습 안정성이 완벽하지 않음
LSGAN	Least Squares Loss 사용	기울기 소실 문제 완화, 안정적인 학습	특정 상황에서만 적합하며, 모든 애플리케이션에서 일반적으로 활용되기 어려움
PGGAN	점진적 네트워크 확장	고해상도 이미지에서 뛰어난 성능	학습 시간이 오래 걸림
cGAN	조건 기반 이미지 생성	특정 특성을 가진 데이터 생성 가능	조건 데이터 필요
StyleGAN	스타일 조정 및 고품질 이미지 생성	이미지 다양성 및 속성 제어 가능	복잡한 구조, 높은 계산 비용

4. 변형 GAN의 응용

- **DCGAN:** 이미지 생성 및 복원.
- **WGAN:** 안정적인 고품질 데이터 생성.
- **cGAN:** 클래스 조건 이미지 생성 (예: 특정 숫자 또는 속성).
- **StyleGAN:** 인물 사진, 캐릭터 디자인.