

GAN 확률밀도함수 설명



GAN에서 사용되는 확률밀도함수란

GAN에서 말하는 **확률밀도함수(PDF, Probability Density Function)**는 사실 수식으로 직접 다루는 “수학 공식”이 아니라, **GAN이 근본적으로 학습하려는 대상을 이론적으로 표현하기 위해 등장하는 개념**이에요.

즉:

GAN은 데이터의 ‘확률분포(확률밀도함수)’를 직접 모델링하려고 하는 생성 모델이다.

아주 쉽게 풀어볼게요.

✓ 1. 우리가 GAN으로 배우려는 것 = 데이터의 확률분포 $p_{data}(x)$

MNIST 예를 들어 보자.

- MNIST 실제 숫자 이미지들은 어떤 “규칙과 패턴”을 갖고 있음
- 그 규칙을 수학적으로 표현하면 $p_{data}(x)$ 라는 **확률밀도함수**

즉:

실제 이미지가 존재하는 “분포(Distribution)”

GAN의 목표:

👉 **실제 데이터의 분포 $p_{data}(x)$ 를**

👉 **생성기 G가 만들어내는 분포 $p_g(x)$ 와 일치시키는 것**

✓ 2. 그러면 “확률밀도함수”는 어디서 나오나요?

GAN은 아래 두 가지 분포를 다룸:

1 노이즈 z 의 분포

- 보통 난수 $z \sim N(0,1)$ (정규분포)
- 또는 **Uniform(-1, 1)**

이건 **명시적인 확률밀도함수(PDF)** 를 가지고 있음

예:

$N(0,1)$ 의 PDF

$$p_z(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$$

2 실제 이미지의 분포 $p_{\text{data}}(x)$

- 이걸 “수식으로 존재하지 않음”
- 우리가 가진 데이터셋이 샘플 역할을 해서 대신함

즉 GAN은:

- z 는 명시적인 PDF를 가진 확률분포
- x 는 샘플링된 데이터 분포(암묵적 PDF)

3. 생성기 G 는 분포 변환기

노이즈 z 를 x 로 바꾸는 함수가 생성기 G :

$$x = G(z)$$

그러면 x 의 분포를 $p_g(x)$ 라고 부름.
이것도 명시적인 식이 없음 (복잡하니까)

4. GAN의 목적함수에 “확률”이 등장하는 이유

GAN 논문 수식:

$$\min_G \max_D V(D, G) = E_{x \sim p_{\text{data}}} [\log D(x)] + E_{z \sim p_z} [\log(1 - D(G(z)))]$$

여기서 $E[\cdot]$ 기대값은 모두 확률분포 위에서 계산됨.

즉:

- $D(x)$ 는 실제 데이터 분포 $p_{\text{data}}(x)$ 에 대한 기대값
- $D(G(z))$ 는 생성 분포 $p_g(x)$ 에 대한 기대값

📌 핵심정리 (초간단 정리)

종류	등장하는 확률분포	확률밀도함수(PDF)
노이즈 z	$p_z(z)$	명시적인 PDF 있음 (정규분포 등)
실제 데이터 x	$p_{\text{data}}(x)$	수식 없음 → 데이터 샘플로 근사
생성된 데이터 $G(z)$	$p_g(x)$	수식 없음 → 모델이 암묵적으로 학습

👍 제일 쉬운 한 줄 정의

GAN에서 확률밀도함수는 “실제 데이터가 어떤 패턴을 가진 분포인지”를 뜻하며, 생성기는 그 분포를 학습해서 비슷한 분포를 가진 가짜 데이터를 만들려는 모델이다.

원하면

- “확률밀도함수가 GAN에서 어떻게 쓰이는지”
- “VAE와 비교한 확률모델 차이”
- “implicit model vs explicit model”
도 바로 더 쉽게 정리해줄게!



조건부확률과 GAN

조건부확률(Conditional Probability)이 **GAN**에서 직접적으로 공식처럼 등장하지는 않지만, GAN의 이론적 구조 전체는 사실 **조건부확률의 개념** 위에서 돌아가고 있어요.

아주 쉽게 “왜 GAN이 조건부확률과 연결되는지”를 정리해줄게요.

🎯 1. 기본 GAN = 조건부확률을 암묵적으로 사용한다

Discriminator(판별자) $D(x)$ 의 본질

$D(x)$ 는 사실 **조건부확률을 근사하는 모델**임.

$$D(x) \approx P(\text{real} \mid x)$$

즉,

“이미지 x 가 주어졌을 때, 그것이 진짜일 확률”

이게 바로 **조건부확률 $P(\text{real} \mid x)$** .

Generator G 의 목표는?

G 는 원하는 것이:

$$P(\text{real} \mid G(z)) \text{ 를 최대화}$$

즉:

노이즈 z 로부터 생성한 이미지 $G(z)$ 가 **진짜일 확률**을 최대화

이것도 조건부확률의 구조.

2. GAN의 목적 함수 자체가 조건부확률 기반

GAN의 기본 loss:

$$\min_G \max_D V(D, G) = E_{x \sim p_{data}} [\log D(x)] + E_{z \sim p_z} [\log(1 - D(G(z)))]$$

여기서 $D(x)$ 란?

$$D(x) = P(\text{real} | x)$$

따라서 식은 이렇게 해석할 수 있음:

- 진짜 이미지가 들어왔을 때 진짜일 확률을 최대화
- 가짜 이미지가 들어왔을 때 가짜일 확률을 최대화
- G는 반대로, 가짜 이미지가 진짜일 확률을 최대화

전부 조건부확률!

3. Conditional GAN(cGAN) = 조건부확률을 명시적으로 사용

이건 더 명확해짐.

cGAN은 아래 확률을 직접 모델링:

$$G(z, y) \sim P(x | y)$$

예:

- $y = \text{"3"} \rightarrow \text{"3 이미지" 생성}$
- $y = \text{"고양이"} \rightarrow \text{"고양이 이미지" 생성}$
- $y = \text{"여름 스타일"} \rightarrow \text{여름풍 이미지 생성}$

즉 cGAN은 조건부 생성 모델

cGAN의 판별자도 조건부확률을 학습

$$D(x, y) = P(\text{real} | x, y)$$

의미:

“(이미지 x , 조건 y)가 함께 들어왔을 때, 그게 진짜인지”

4. 결국 GAN은 조건부확률의 전쟁

GAN은 이렇게 요약 가능:

- **D: $P(\text{real} \mid \mathbf{x})$ 를 학습**
- **G: $P(\text{real} \mid G(\mathbf{z}))$ 를 높이도록 학습**
- **cGAN: $P(\mathbf{x} \mid \mathbf{y})$ 를 학습**

둘 다 조건부확률의 형태.

GAN의 로직이 이렇게 변환됨:

역할	확률 관점
Discriminator	$P(\text{real}$
Generator	$P(\text{real}$
Conditional GAN	$P(\mathbf{x}$

5. GAN은 '암묵적 모델(Implicit Model)'이라 확률을 수식으로 모델링하지 않는다

VAE는 명시적 확률모델:

$p(\mathbf{x} \mid \mathbf{z})$ 를 직접 정의

(PDF, likelihood 존재)

반면 GAN은:

- $p_{\text{g}}(\mathbf{x})$ (생성된 이미지의 확률분포) 수식 없음
- 대신 D가 제공한 조건부 확률 $P(\text{real} \mid \mathbf{x})$ 신호로 업데이트

즉:

GAN은 조건부 확률을 '라벨 신호'처럼 이용해 분포를 따라가도록 유도하는 모델.

한 줄 핵심정리

GAN은 “이미지 $\mathbf{x}$ 가 진짜일 확률 $P(\text{real} \mid \mathbf{x})$ ”를 학습하는 판별자와, “가짜를 진짜처럼 보일 조건부확률을 높이려는 생성자”의 게임이다.

즉 GAN 전체는 조건부확률 위에서 동작한다.

원하면 더 해줄 수 있어요

- BCE loss가 왜 조건부확률의 로그우도 형태인지

- GAN과 베이지안 확률관계
- cGAN vs VAE-CVAE 비교
- 이미지 세그멘테이션·OCR에서 conditional GAN 활용 사례

원하는 흐름으로 더 깊게 이어갈까?



베이지정리 와 gan

GAN을 “베이지 정리 관점에서 보면 어떻게 이해되는가?”
이걸 가장 직관적 + 실전적으로 정리해줄게.

1. 결론부터

GAN은 베이지 정리를 직접 사용하지 않는다.
그러나 GAN의 핵심 개념인

- 판별자 $D(x)$ 가 학습하는 확률
- 생성자 G 가 최대화하려는 확률

이 두 가지는 모두 베이지 정리의 구조로 해석될 수 있다.

즉,

GAN은 베이지 정리를 직접 계산하지는 않지만,
 $D(x) = P(\text{real} \mid x)$ 자체가 이미 베이지적 확률 모델이다.

2. 베이지 정리 복습 (초간단)

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

의미:

“B가 관측되었을 때, A일 확률”

3. GAN에서 판별자 $D(x)$ 는 베이지 정리의 형태

판별자 $D(x)$ 의 의미는:

$$D(x) = P(\text{real} \mid x)$$

즉,

“이미지 x 가 주어졌을 때 그게 진짜일 확률”

이건 정확히 **베이즈 정리의 오른쪽 구조다**.

D(x)를 베이즈 정리로 표현해보면?

$$P(\text{real} | x) = \frac{P(x | \text{real})P(\text{real})}{P(x | \text{real})P(\text{real}) + P(x | \text{fake})P(\text{fake})}$$

여기서:

- $P(x | \text{real})$ = 실제 데이터가 만드는 likelihood
- $P(x | \text{fake})$ = $G(z)$ 가 만드는 likelihood
- $P(\text{real}), P(\text{fake})$ = 사전확률 프라이어
- (보통 둘 다 0.5로 세팅됨)

이 수식은 “이상적 판별자(optimal discriminator)”가 되어야 하는 형태 그대로이다.

🎯 4. 실제 GAN 논문에서도 이 베이즈 형태가 등장함

GAN 논문에서 “최적 판별자” $D^*(x)$ 는:

$$D^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$$

이걸 베이즈 정리로 보면:

- 분자 = **likelihood × prior**
- 분모 = 정규화 상수 (evidence)

즉, 논문 속 최적판별자는 **베이즈 정리 그대로**이다.

🎯 5. 생성자 G는 무엇을 하나?

G는 아래 확률을 최대화하고 싶다:

$$P(\text{real} | G(z))$$

그러면

$G(z)$ 가 real일 조건부확률을 최대화

→ 즉 “베이즈적 판단에서 real로 분류될 확률을 높이는 것”

🎯 6. GAN의 게임 구조 전체가 베이즈 프레임으로 설명 가능

역할	확률 해석	베이지스 관점
D(x)	P(real	x)
p(x	real)	실제 이미지의 likelihood
p(x	fake)	가짜 이미지의 likelihood
G(z)	fake 분포 p_g(x) 생성	likelihood 바꾸는 과정
판별자 학습	posterior 정확하게	베이지스 classifier 최적화
생성자 학습	posterior 속이기	posterior 값을 높이기

즉,

GAN = posterior(사후확률)를 두고 싸우는 게임

7. 베이지스 정리를 GAN에서 왜 안 쓰는데 중요하냐?

GAN은 **explicit probability model**이 아니라 **implicit probability model**이기 때문.

즉:

- VAE처럼 직접 $p(x|z)$ 를 정의해서 likelihood를 계산하지 않음
- 대신 D(x)라는 베이지스적 posterior를 이용해 “우회적으로” 학습함

GAN = likelihood를 직접 계산하지 않지만 posterior(조건부확률)를 통해 분포를 학습하는 베이지스적 구조

8. 가장 쉬운 직관 요약

Discriminator = 베이지스 분류기

$$P(real|x) = \frac{p(x|real)p(real)}{p(x)}$$

Generator = 이 posterior가 real에 가까워지도록 fake 分布 p_g(x)을 변형하는 기계

1줄 요약

GAN은 베이지스 정리를 직접 계산하지 않지만,
판별자의 의미인 $P(real | x)$ 는 베이지스 정리에 기반한 사후확률이며,
GAN 전체는 베이지스적 구조 위에서 동작하는 생성 모델이다.

원하면 이어서:

- ✓ GAN과 VAE 비교 (explicit vs implicit)
- ✓ GAN에서 prior(사전확률) 의미
- ✓ Bayesian GAN 논문 구조
- ✓ 베이지 정리로 GAN loss 완전 해석하기

도 더 깊게 정리해줄게!



이산, 연속 데이터 + 확률

아주 핵심만 **초간단 + 직관적**으로 정리해줄게.
(세그멘테이션·GAN·ML에서 왜 필요한지도 같이!)

🎯 1. 이산확률분포 (Discrete Probability)

값이 **뚝뚝 끊어져** 있고,
세거나(Countable) 가능한 경우.

예:

- 주사위 눈 1~6
- MNIST 라벨 0~9
- 세그멘테이션 클래스 0~20
- “고양이냐 아니냐” (0/1)
- GAN에서 진짜/가짜(0/1)

이산확률은 **확률 질량 함수(PMF)** 를 쓴다.

$$P(X = x)$$

예)

$$P(\text{고양이}) = 0.3$$

🎯 2. 연속확률분포 (Continuous Probability)

값을 **세지 못하고**,
구간 내에서 **무한히 많은 값**을 가질 수 있음.

예:

- 키 172.53 cm
- RGB 픽셀값 (연속화 가능)
- GAN 노이즈 $z \sim N(0, 1)$

- 이미지 픽셀의 float intensity
- 평균, 분산 등 실수 값

연속확률은 **확률밀도함수(PDF)** 를 쓴다.

$$f(x)$$

연속변수에서 특정 값의 확률은 0:

$$P(X = 5) = 0$$

대신 구간확률로 쓴다:

$$P(4 < X < 6) = \int_4^6 f(x) dx$$

3. 둘의 차이를 가장 쉽게

구분	이산	연속
값	0,1,2,3... 같은 정수	3.1415..., 실수
확률	PMF $P(X=x)$	PDF $f(x)$
점확률	있음	없음(0)
예	클래스라벨, 0/1, 주사위	노이즈 z , 키, 픽셀float

4. 머신러닝에서의 연결

✓ 분류(Classification) 모델 = 이산 확률

소프트맥스, BCE, GAN 판별자, 세그멘테이션 등
전부 이산확률을 예측한다.

- 세그멘테이션 0/1/2/3...
- GAN $D(x)$ 는 0~1 확률 (이산 클래스: real/fake)
- Softmax → 클래스 확률

✓ 생성모델(GAN, VAE) 내부 = 연속 확률

- GAN의 노이즈 $z \sim$ 연속 확률분포
(일반적으로 $N(0,1)$)

확률밀도함수 PDF를 갖는다.

🎯 5. GAN에 적용하면?

1) 노이즈 z = 연속 분포

$$z \sim N(0, 1)$$

→ PDF가 존재

2) 이미지 x = 연속처럼 다룸 (float tensor)

3) 진짜/가짜 label = 이산 분포

$$P(\text{real}|x), P(\text{fake}|x)$$

즉 GAN에서 동시에:

항목	종류	이유
노이즈 z	연속	정규분포
생성 이미지	연속(real-valued)	픽셀이 실수
라벨(real/fake)	이산	0/1 분류 문제

🎯 6. 세그멘테이션에도 적용하면

이산확률

- 클래스 마스크 0,1,2 ... 20
- 소프트맥스 → 각 픽셀의 이산확률 $P(\text{Class}=k \mid \text{pixel})$

연속확률

- 픽셀값 float (0~255 → 0~1 스케일)
- augmentation 시 continuous interpolation 사용

🎯 7. 한 방에 정리 (초간단)

이산 = 분류 / 라벨용 확률

연속 = 실수 값 / 노이즈 / 픽셀 / 모델 내부 계산용

GAN, 세그멘테이션, 분류 모두 이 두 종류를 섞어서 쓰는 구조다.

원하면 이어서

- 소프트맥스(PMF) vs 정규분포(PDF) 직관

- BCE Loss가 왜 이산확률 기반인지
- GAN 생성자는 왜 연속확률변수를 써야 하는지
- VAE에서 PDF를 직접 모델링하는 이유

도 바로 풀어줄게!



이미지를 0~255로 정규화 시키지 않았을때 노이즈값은 이산, 연속?

결론부터 정확하게 한 줄로 말하면:

✅ ****이미지가 0~255 정수(정규화 안 함)여도**

노이즈 z 는 “연속 확률변수”다.**

이미지 정규화 여부와 상관없이

GAN 노이즈는 항상 연속 확률분포(PDF)를 가진다.

이제 왜 그런지 초간단 + 아주 직관적으로 설명해줄게.

🎯 1. “이미지 0~255 정수” → 이산인가 연속인가?

- 픽셀값이 **정수(0~255)** 이면
→ 이산적(discrete) 값처럼 보임
- 그러나 GAN·딥러닝 내부에서는
→ float32로 캐스팅되어 연속값으로 취급됨

즉 실제 코드에서는:

```
python

real = real.float() # float tensor로 변환됨
```

그래서 “모양만 정수”일 뿐,
연속적 계산(실수 연산)을 한다.

그러나 중요한 건 ↓↓↓

🎯 2. 노이즈 z 의 분포는 이미지에 영향을 받지 않는다

GAN의 노이즈는 다음처럼 정의:

$$z \sim \mathcal{N}(0, 1)$$

또는

$$z \sim U(-1, 1)$$

즉 정규분포(PDF) 또는 연속적 균일분포(PDF).

그래서 z 는 무조건 연속 확률변수다.

🎯 3. 만약 이미지가 0~255 정수라면?

이건 진짜 중요한 포인트.

이미지가 정수라 해도:

- Generator는 z (연속)를 입력으로 이미지(real-valued float)를 만든다.
- Discriminator는 이미지(float)를 보고 확률(real/fake)을 낸다.

이미지 자체가 이산적이어도

모델 내부에서는 연속값으로 변환되어 연속 공간에서 학습이 일어남.

따라서 이미지 스케일과 관계없이:

👉 노이즈는 연속

👉 모델 파라미터도 연속

👉 $D(x)$ 확률도 연속

👉 Loss도 연속

이미지가 정수냐 아니냐는 중요하지 않음.

🎯 4. 한 방에 결론

항목	이산?	연속?	이유
이미지 (0~255 정수 그대로)	표면적으로 이산	실질적으로 연속	float32로 처리됨
노이즈 z	❌ 이산 아님	연속	정규분포/균일분포 PDF
GAN loss	연속	Log-loss, sigmoid 모두 연속	

🎯 5. 직관적으로 말하면

GAN은 "연속 확률공간"에서 동작하는 알고리즘

이미지가 정수든 float든 상관 없이

파라미터, 노이즈, 확률값은 전부 실수 기반.

그래서 노이즈는 무조건 연속확률변수.

한 줄 최종 정답

이미지를 0~255로 정규화하지 않았어도
GAN의 노이즈 z 는 항상 연속 확률분포(PDF)를 따른다.

원하면

- “왜 이미지 정규화를 그래도 하는지?”
- “정수 이미지 넣었을 때 학습 영향”
- “픽셀을 이산으로 진짜 다룰 수는 없는지?”
도 이어서 바로 설명해줄게!